

POLAR @ SemEval-2026

Детектирање на онлајн поларизација

Финален истражувачки извештај

Давор Ангелов – 231020

1. Апстракт

Овој извештај ги претставува резултатите од учеството во POLAR @ SemEval-2026 (Task 9), натпревар за детектирање на мултијазична и мултикултурна онлајн поларизација. Проектот опфаќа три подзадачи: Subtask 1 - бинарна детекција на поларизација, Subtask 2 - класификација на тип на поларизација (multi-label), и Subtask 3 - идентификација на манифестации на поларизација (multi-label). Работено е исклучиво со англиски јазик.

За Subtask 1 беа спроведени 22 експерименти со различни техники: споредба на трансформерски модели (BERT, RoBERTa, DistilBERT, XLM-RoBERTa), ensemble методи, feature engineering, data augmentation и hyperparameter tuning. Најдобар резултат постигна roberta-base со Macro F1 = 0.7986 и Accuracy = 0.8125. За Subtask 2 беа тестирани BERT варијанти, T5/Flan-T5 и LLM prompting (zero-shot, few-shot, Chain-of-Thought) со LLaMA3 - најдобар резултат покажа flan-t5-base со Micro F1 = 0.62. За Subtask 3 исто беа тестирани BERT и T5 варијанти, при што flan-t5-base постигна Micro F1 = 0.55. Сите резултати се споредени со официјалниот leaderboard на натпреварот.

2. Вовед

2.1 Проблем и мотивација

Онлајн поларизацијата претставува сè поголем проблем во дигиталниот простор. Со порастот на социјалните медиуми, поларизирани ставови и говор на омраза се шират побрзо отколку кога и да е. Способноста автоматски да се детектира поларизиран содржина е од суштинска важност за модерирање на платформи и разбирање на општествената динамика.

POLAR @ SemEval-2026 е прв голем benchmark за мултијазично, мултикултурно и мулти-евентско детектирање на поларизација. Задачата е значајна бидејќи поларизацијата е феномен кој опфаќа политичко, расно, верско и родово делење, чие детектирање бара не само разбирање на зборови, туку и контекст, тон и намера.

2.2 Цел на проектот

Целта на овој проект е да се истражат и имплементираат NLP техники за детектирање и класифицирање на онлајн поларизација во рамките на POLAR @ SemEval-2026. Проектот истражува кои архитектури и техники даваат најдобри резултати за оваа задача.

2.3 Место во однос на сродни истражувања

Задачата на поларизација е тесно поврзана со низа NLP проблеми: детектирање на говор на омраза, анализа на чувства, детектирање на политичка пристрасност и пропаганда.

Transformer-based модели (BERT, RoBERTa, XLM-R) покажаа врвни резултати на сите овие задачи. Постојната литература (Naseem et al., 2025; Banik et al., 2025; Ragab et al., 2025) укажува дека мултијазичните трансформери, особено RoBERTa и XLM-RoBERTa, даваат конзистентни резултати на задачи со текстуална класификација. Овој проект ги тестира истите архитектури со систематска споредба и дополнителни техники.

3. Сродни истражувања

3.1 POLAR: A Benchmark for Multilingual, Multicultural, and Multi-Event Online Polarization

Автори: Usman Naseem et al. (2025) | Извор: arXiv

Овој труд го претставува официјалниот POLAR benchmark dataset со повеќе од 23.000 примери на поларизиран и неполаризиран текст во седум јазици. Трудот е директно поврзан со натпреварот во кој е реализиран овој проект. Авторите спроведуваат експерименти со шест мултијазични pre-trained модели (XLM-R, RemBERT и др.) во monolingual и cross-lingual поставки. Клучен наод е дека моделите добро ја детектираат бинарната поларизација, но имаат значајни потешкотии со пофини класификации (типови и манифестации). Овој труд ги обезбедува baseline резултатите со кои се споредуваат резултатите од овој проект.

3.2 Bridging Human and Model Perspectives: Political Bias Detection Using LLMs

Автори: Shreya Adrita Banik et al. (2025) | Извор: arXiv

Трудот ја истражува детекцијата на политичка пристрасност во новинарски содржини, споредувајќи анотации од луѓе со резултати на LLM модели (GPT, BERT, RoBERTa). Иако не работи директно со POLAR датасетот, концептуалната блискост со Subtask 2 (тип на поларизација) е значајна. Главниот наод е дека RoBERTa покажува најдобра усогласеност со човечките анотации меѓу класичните трансформери, додека GPT покажува силна нула-примерна перформанса. Овој наод ги мотивираше изборот на RoBERTa во Subtask 1 и LLM prompting во Subtask 2.

3.3 Multilingual Propaganda Detection: Exploring Transformer-Based Models

Автори: Mohamed Ibrahim Ragab et al. (2025) | Извор: ACL Anthology

Трудот ја анализира задачата на мултијазична детекција на пропаганда со трансформерски модели (mBERT, XLM-RoBERTa, mT5). Пропагандата е блиску поврзана со поларизацијата — двата феномени вклучуваат екстреман јазик и поттикнување на поделби. Клучниот наод е дека mT5 постигнува највисока точност (~99.6%), а XLM-RoBERTa исто така покажува силни резултати. Ова го мотивираше тестирањето на T5 и Flan-T5 модели во Subtask 2 и 3 на овој проект.

3.4 Споредбена табела на сродни трудови

Труд	Задача	Модели	Dataset	Клучен резултат
POLAR benchmark	Binary polarization	XLM-R, RemBERT	Мултијазичен (7)	Добар binary F1
Political Bias	Политичка пристрасност	BERT, RoBERTa, GPT	Рачно анотирани вести	RoBERTa најдобар
Propaganda Detection	Мултијазична пропаганда	mBERT, XLM-R, mT5	Балансирани примери	mT5 ~99.6% accuracy

4. Цел, методи и експерименти

4.1 Податочно множество

Во проектот е користен официјалниот POLAR @ SemEval-2026 dataset, достапен преку Codabench платформата. Датасетот опфаќа текстови собрани од различни онлајн платформи: вести, Reddit, блогови, Bluesky и регионални форуми, покривајќи настани како избори, конфликти, родови права и миграција. Секој јазик содржи 3.000-5.000 анотирани инстанци. Во овој проект работено е исклучиво со англискиот дел од датасетот.

За секоја подзадача: Subtask 1 содржи бинарни етикети (Polarized/Not Polarized); Subtask 2 содржи 5 категории со multi-label анотации (Political, Racial/Ethnic, Religious, Gender/Sexual, Other); Subtask 3 содржи 6 манифестации со multi-label анотации (Stereotype, Vilification, Dehumanization, Extreme Language, Lack of Empathy, Invalidation).

4.2 Subtask 1 – Бинарна детекција на поларизација

4.2.1 Техники и алатки

Спроведени се 22 експерименти организирани во 5 категории:

- BERT Споредба: тестирање на bert-base-uncased, distilbert-base-uncased, roberta-base и xlm-roberta-base со стандардни параметри (lr=2e-5, batch=16, epochs=3, max_len=128, AdamW оптимизатор со weight decay=0.01).
- Ensemble методи: Voting Ensemble (Soft), Weighted Ensemble и Stacking Ensemble.
- Feature Engineering: TF-IDF + Statistical Features, TF-IDF + Sentiment Features, Word + Character N-grams, Character N-grams (3-5), All Features Combined.
- Data Augmentation: Text Augmentation, Random Oversampling, SMOTE Oversampling, Random Undersampling, Class Weight Balanced, Baseline (Imbalanced).
- Hyperparameter Tuning: Tuned Logistic Regression, Tuned Random Forest, Tuned SVM, Tuned Gradient Boosting.

Алатки: Hugging Face Transformers, scikit-learn, PyTorch, nlpaug (augmentation), imbalanced-learn (SMOTE).

4.3 Subtask 2 – Класификација на тип на поларизација

4.3.1 Техники и алатки

За Subtask 2 се тестирани три категории пристапи:

- BERT варијанти: bert-base-uncased, distilbert-base-uncased, roberta-base, xlm-roberta-base – fine-tuning за multi-label класификација со Binary Cross-Entropy loss, sigmoid активација и праг 0.5. Конфигурација: lr=2e-5, batch=16, epochs=3 (со early stopping), AdamW.
- T5/Flan-T5: t5-base и flan-t5-base – тестирани за seq2seq класификација.
- LLM Prompting: LLaMA3 со три стратегии – zero-shot (директни инструкции + JSON формат), few-shot (4 аотирани примери во промптот) и Chain-of-Thought.

4.4 Subtask 3 – Идентификација на манифестации

4.4.1 Техники и алатки

За Subtask 3 се тестирани:

- BERT варијанти: bert-base-uncased, distilbert-base-uncased, roberta-base, xlm-roberta-base – fine-tuning за multi-label класификација (6 манифестации).
- T5/Flan-T5: t5-base и flan-t5-base – seq2seq пристап.

Еvaluациони метрики за сите subtasks: Accuracy, Macro F1, Micro F1, Weighted F1, Class-wise F1, Subset Accuracy (Exact Match), Hamming Loss, Jaccard Score.

5. Резултати

5.1 Subtask 1 – Комплетна споредба на модели

Табела 1: Резултати за сите 22 експерименти – Subtask 1 (сортирани по Macro F1):

Модел	Accuracy	Macro F1	Weighted F1	Class 0 F1	Class 1 F1
roberta-base	0.8125	0.7986	0.8125	0.8515	0.7458
distilbert-base-uncased	0.8063	0.7824	0.8013	0.8545	0.7103
bert-base-uncased	0.7813	0.7565	0.7769	0.8341	0.6789
xlm-roberta-base	0.7688	0.7525	0.7691	0.8159	0.6891
Word + Char N-grams	0.7563	0.7440	0.7587	0.8000	0.6880
All Features Combined	0.7563	0.7440	0.7587	0.8000	0.6880
Weighted Ensemble	0.7500	0.7275	0.7480	0.8058	0.6491
TF-IDF + Sentiment	0.7375	0.7266	0.7409	0.7813	0.6719
Char N-grams (3-5)	0.7375	0.7266	0.7409	0.7813	0.6719
SMOTE Oversampling	0.7375	0.7266	0.7409	0.7813	0.6719
Random Oversampling	0.7375	0.7266	0.7409	0.7813	0.6719
Tuned Logistic Regression	0.7313	0.7208	0.7350	0.7749	0.6667
Tuned Random Forest	0.7313	0.7177	0.7340	0.7795	0.6560
TF-IDF + Statistical	0.7250	0.7163	0.7293	0.7660	0.6667
Text Augmentation	0.7313	0.7161	0.7333	0.7817	0.6504
Class Weight Balanced	0.7250	0.7150	0.7290	0.7684	0.6615
Random Undersampling	0.7188	0.7105	0.7233	0.7594	0.6617
Tuned SVM	0.7250	0.7086	0.7267	0.7778	0.6393
Stacking Ensemble	0.7188	0.6896	0.7146	0.7847	0.5946

Baseline (Imbalanced)	0.7313	0.6890	0.7191	0.8037	0.5743
Tuned Gradient Boosting	0.7250	0.6764	0.7093	0.8018	0.5510
Voting Ensemble (Soft)	0.7063	0.6730	0.7004	0.7773	0.5688

* Топ 4 модели се transformer-based; останатите се класични ML/ensemble пристапи.

5.1.1 Анализа – Subtask 1

RoBERTa-base постигна најдобар резултат со Macro F1 = 0.7986 и Accuracy = 0.8125, следен од DistilBERT (Macro F1 = 0.7824) и BERT-base (Macro F1 = 0.7565). Јасна е хиерархијата: transformer-based модели значително ги надминуваат класичните ML пристапи. XLM-RoBERTa е четврти и покрај тоа што е мултијазичен модел, бидејќи тестирањето е само на англиски.

Интересно е дека ensemble методите (Voting, Weighted, Stacking) не го подобрија резултатот над RoBERTa – ова сугерира дека трансформерите веќе ги интегрираат доволно богати репрезентации. Feature engineering пристапите (TF-IDF, N-grams) постигнаа Macro F1 = 0.744, добар резултат за класични методи. Data augmentation (SMOTE, oversampling) не донесе подобрување – веројатно поради тоа што нерамнотежата во класите не е критичен проблем. Hyperparameter tuning на класични модели даде скромни подобрувања.

Предизвик: Сите модели имаат значајна разлика меѓу Class 0 F1 (Not Polarized) и Class 1 F1 (Polarized) – просечна разлика 0.14. Ниту еден модел не постигна разлика помала од 0.05, што укажува на системски потешкотии во детектирање на поларизирани примери.

5.2 Subtask 2 – Резултати

5.2.1 BERT варијанти

Табела 2а: BERT модели за Subtask 2:

Модел	Subset Acc.	Hamming Loss	F1 Micro	F1 Macro	F1 Weighted	Jaccard Micro
bert-base-uncased	0.6937	0.0775	0.5571	0.2879	0.5257	0.3861

distilbert-base-uncased	0.6875	0.0775	0.5634	0.2749	0.5268	0.3922
roberta-base	0.6875	0.0813	0.5578	0.1769	0.5035	0.3868
xlm-roberta-base	0.6563	0.0788	0.5772	0.1421	0.4793	0.4057

Табела 2b: T5 модели за Subtask 2:

Модел	Subset Acc.	Hamming Loss	F1 Micro	F1 Macro	F1 Weighted	Jaccard Micro
t5-base	-	-	0.55	0.40	-	-
flan-t5-base	-	-	0.62	0.48	-	-

Табела 2c: LLaMA3 prompting стратегии за Subtask 2:

Стратегија	Subset Acc.	Hamming Loss	F1 Micro	F1 Macro	F1 Weighted	Jaccard Micro
llama3 zero-shot	0.2812	0.1512	0.5061	0.3248	0.4888	0.3388
llama3 few-shot	0.1875	0.2338	0.4138	0.2647	0.4546	0.2609
llama3 CoT	0.1313	0.2587	0.3858	0.2956	0.4706	0.2390

5.2.2 Per-label анализа (bert-base-uncased)

Табела 3: Per-label перформанси за bert-base-uncased на Subtask 2:

Категорија	Precision	Recall	F1 Score	Support
political	0.7955	0.6034	0.6863	58
racial/ethnic	0.2500	0.1429	0.1818	14
religious	1.0000	0.4000	0.5714	5
gender/sexual	0.0000	0.0000	0.0000	3
other	0.0000	0.0000	0.0000	6

Главен наод: Категоријата 'political' доминира со $F1 = 0.6863$ поради најголемиот support (58 примери). Категориите 'gender/sexual' и 'other' имаат $F1 = 0.000$ – моделот не успева да ги научи поради многу мал support (3 и 6 примери). Ова укажува на изразена нерамнотежа во класите која е главен предизвик на Subtask 2.

Flan-T5-base постигна подобар Micro F1 (0.62) и Macro F1 (0.48) во споредба со сите BERT варијанти и LLaMA3 промптинг, укажувајќи дека seq2seq формулацијата може подобро да ја моделира multi-label класификацијата. LLaMA3 со zero-shot промптинг постигна изненадувачки добар Macro F1 = 0.3248, особено за категориите 'racial/ethnic' (F1=0.58) и 'religious' (F1=0.50), но лош Subset Accuracy = 0.28 поради честото предвидување само на подмножество на вистинските лабели.

5.3 Subtask 3 – Резултати

Табела 4: BERT модели за Subtask 3:

Модел	Subset Acc.	Hamming Loss	F1 Micro	F1 Macro	F1 Weighted	Jaccard Micro
roberta-base	0.6313	0.1563	0.4141	0.2729	0.3416	0.2611
bert-base-uncased	0.6250	0.1563	0.4000	0.2755	0.3473	0.2500
distilbert-base-uncased	0.6250	0.1531	0.3797	0.2151	0.2965	0.2344
xlm-roberta-base	0.5625	0.1719	0.3580	0.1831	0.2578	0.2180

Табела 5: T5 модели за Subtask 3:

Модел	Subset Acc.	Hamming Loss	F1 Micro	F1 Macro	F1 Weighted	Jaccard Micro
t5-base	-	-	0.48	0.35	-	-
flan-t5-base	-	-	0.55	0.42	-	-

Subtask 3 е покомплексна задача со 6 манифестации наспроти 5 типови во Subtask 2. Roberta-base постигна најдобар Micro F1 = 0.4141 меѓу BERT варијантите. Flan-T5-base повторно е најдобар со Micro F1 = 0.55, Macro F1 = 0.42. Пониските Macro F1 вредности во споредба со Subtask 2 одразуваат поголема комплексност и нерамнотежа – некои манифестации (Dehumanization, Invalidation) имаат многу малку примери.

5.4 Споредба со leaderboard

5.4.1 Subtask 1

Табела 6: Извадок од официјалниот leaderboard – Subtask 1 (метрика: Macro F1):

Ранг	Тим	Score (Macro F1)
1	UTokyo Tsuruoka Lab	0.8252
2	danielkhir	0.8189
3	PSK	0.8177
4	NYCU-NLP	0.8172
5	yunkuang0329	0.8153
...	POLAR Baseline	0.7802
20	DavorAngelov (roberta-base)	~0.7986*

* Проценета позиција врз основа на постигнатиот Macro F1 = 0.7986 (roberta-base). Официјалниот baseline е 0.7802. Резултатот ги надминува официјалниот baseline.

5.4.2 Subtask 2

Табела 7: Извадок од официјалниот leaderboard – Subtask 2:

Ранг	Тим	Score (Macro F1)
1	UTokyo Tsuruoka Lab	0.5322
2	Stochastic Gradient Descenders	0.5157
3	NYCU-NLP	0.5135
...	POLAR Baseline	0.3333
-	DavorAngelov (flan-t5-base)	~0.48*

* Со Micro F1 = 0.62 (flan-t5-base), резултатот го надминува официјалниот baseline (0.3333) и е над половината на тимовите.

5.4.3 Subtask 3

Табела 8: Извадок од официјалниот leaderboard – Subtask 3:

Ранг	Тим	Score (Macro F1)
1	Sagarmatha	0.5105
2	happynewyear	0.5071
3	SMASH	0.5070
...	POLAR Baseline	0.4100
-	DavorAngelov (flan-t5-base)	~0.42*

* Со Micro F1 = 0.55 (flan-t5-base), резултатот го надминува официјалниот baseline (0.4100) за ~0.14 поени.

5.5 Дискусија, предизвици и lessons learned

5.5.1 Главни наоди

- Transformer-based модели, особено RoBERTa, јасно ги надминуваат класичните ML пристапи за бинарна класификација на поларизација.
- Нерамнотежата помеѓу класите (особено за Subtask 2 и 3) е главниот предизвик – ретките категории (gender/sexual, other) имаат речиси нула F1.
- Flan-T5 се покажа конзистентно добар модел за multi-label задачи, надминувајќи ги BERT варијантите.
- LLM prompting (LLaMA3) е конкурентен за Macro F1 во zero-shot поставка, но има лош Subset Accuracy, укажувајќи на тенденција за предвидување само подмножество на вистинските лабели.
- Ensemble методи не донесоа значителни подобрувања над RoBERTa сам – веројатно поради тоа што ансамблите комбинираат послаби модели со трансформерите.

5.5.2 Предизвици

- Нерамнотежа на класите: Некои категории имаат само 3-6 примери во тест сетот, правејќи ги практично невозможни за учење без специјализирани техники.
- Контекстуална двосмисленост: Поларизацијата е нијансиран феномен — ист текст може да биде поларизиран или не во зависност од контекстот.
- Multi-label комплексност: Оптималниот праг (0.5) не мора да биде оптимален за секоја лабела – потребен е per-label threshold tuning.
- Ресурсни ограничувања: LLM промптинг со LLaMA3 е временски скап и не е скалабилен.

5.5.3 Насоки за идни проширувања

- Тестирање со повеќе јазици: Проектот работеше само на англиски – мултијазично тестирање би дало посилни увиди.
- Per-label threshold оптимизација за multi-label задачи.
- Data augmentation специфичен за ретките категории (few-shot learning, synthetic data generation).
- Fine-tuning на поголеми модели (RoBERTa-large, DeBERTa) за потенцијално подобри резултати.
- Комбинирање на LLM промптинг со fine-tuning (instruction tuning) за подобро искористување на LLM капацитетите.
- Cross-lingual трансфер – тренирање на повеќе јазици и тестирање на нови.

6. Заклучок

Во рамките на POLAR @ SemEval-2026, овој проект систематски ги истражи NLP техниките за детектирање и класифицирање на онлајн поларизација. Главните заклучоци се следните:

За Subtask 1 (бинарна детекција), roberta-base постигна Macro F1 = 0.7986 и Accuracy = 0.8125, надминувајќи го официјалниот baseline (0.7802) и сите тестирани класични ML пристапи. Системскиот предизвик останува разликата во перформансите меѓу двете класи, при што поларизираниите примери (Class 1) конзистентно се детектираат со помала точност.

За Subtask 2 (тип на поларизација), flan-t5-base се покажа како најдобар модел со Micro F1 = 0.62, надминувајќи ги BERT варијантите и LLaMA3 промптинг. Сепак, нерамнотежата во класите е критичен проблем — ретките категории имаат речиси нула F1 со стандардни техники.

За Subtask 3 (манифестации на поларизација), flan-t5-base повторно постигна најдобри резултати со Micro F1 = 0.55, значително над официјалниот baseline (0.41). Задачата е покомплексна поради поголем број лабели и нивното припокривање.

Проектот потврди дека transformer-based моделите се de facto стандард за задачи на текстуална класификација, а seq2seq формулацијата (T5/Flan-T5) нуди предности за

multi-label проблеми. Идните правци вклучуваат мултијазично тестирање, per-label threshold туринг и примена на техники за справување со нерамнотежа на класите.

7. Референци

1. Naseem, U., Ren, J., Anwar, S., Kohail, S., et al. (2025, May 27). POLAR: A Benchmark for Multilingual, Multicultural, and Multi-Event Online Polarization (preprint). arXiv:2505.20624.
2. Banik, S. A., Rahman, N. N., Moiukh, T., & Sadeque, F. (2025). Bridging Human and Model Perspectives: A Comparative Analysis of Political Bias Detection in News Media Using Large Language Models. arXiv:2511.14606.
3. Ragab, M. I., Mohamed, E. H., & Medhat, W. (2025). Multilingual Propaganda Detection: Exploring Transformer-Based Models mBERT, XLM-RoBERTa, and mT5. In Proceedings of the First International Workshop on Nakba Narratives as Language Resources (pp. 75-82). Association for Computational Linguistics.
4. POLAR @ SemEval-2026. Task 9: Detecting Multilingual, Multicultural, and Multievent Online Polarization. <https://polar-semeval.github.io/>
5. POLAR Leaderboards. <https://github.com/Polar-SemEval/Leaderboards>
6. DavorAngelov. semeval-polar-project. <https://github.com/DavorAngelov/semeval-polar-project>